

稀疏自编码器特征分解之结构性不可能定理：从无条件信息论封锁到架构定量极限

黑目少女

2026-05-17

1 物理观测与实证动机：叠加态的现实存在

在审视大型语言模型（LLMs）的神经激活空间时。学界长期被一种纯粹的还原论期许所牵引。这种期许假设在连续的高维浮点数矩阵中。必定隐藏着一组绝对的、人类可理解的真实语义实体。稀疏自编码器（Sparse Autoencoders, SAEs）因此被视为一种能够剥离非线性表象的光学棱镜。

然而。近期的实证物理观测无情地划破了这种关于真实特征字典的完美幻想。Paulo 与 Belrose 在 2025 年的实证研究中揭示了一个极度精准且带有毁灭性的现象 [1]。在完全相同的模型架构、相同的训练数据流与顺序下。唯一的变量仅为初始化权重的随机种子 [1]。当训练规模达到 131K 潜在变量时。不同随机种子所收敛出的特征集合其共享比例仅为微弱的 30% [1]。

为了解析这种撕裂。我们必须放弃那些要求模型达到完美香农最优压缩的脆弱假设。大型语言模型在训练轨迹中确实充满了未被折叠的空间与冗余的特征备份。我们将论证的重心。稳稳地降落在一个不容置疑的物理事实上：特征叠加态（Superposition）在现实模型中普遍存在。模型为了在有限的物理维度内维持极高的信息密度。必然会利用高维空间中“近似正交向量数量呈指数级增长”的几何特性。将庞大的特征集合压缩到低维流形之中。目标激活流形从一开始就充满了干涉、折叠与高频叠加的连续几何体。这构成了我们论证的坚实实证基底。

2 无条件信息论封锁：超越架构的非线性不可识别性

既然叠加态与非线性纠缠是客观存在的物理现实。我们就可以直接跃升至无条件信息论深渊。去证明一个超越任何具体架构约束的极限定理。

在这里。我们必须首先确立 SAE 特征提取与无监督解缠结（Unsupervised Disentanglement）之间的严格等价性。解缠结学习的终极目标。是在没有真实标签的监督下。找出一个表征空间。使得其中的单一维度精确对应数据生成过程中的单一真实生成因子。这与 SAE 的核心诉求——在没有概念标签的辅助下。仅依靠重建损失和稀疏先验。从激活空间中提取出对应单一真实语义（Monosemanticity）的字典向量——在数学结构上是完全同构的。

为了闭合这一映射。我们必须明确。LLM 的激活空间并非凭空产生，而是可以被严谨地视为 / 某个隐式生成过程（Implicit generative process）的观测值。在真实语料的驱动下。潜藏的、独立的真实语义因子（潜在变量 Z ），通过 LLM 的前向传播网络（非线性生成函数 g ），被投射为高维的激活流形 $X = g(Z)$ 。SAE 正是在这组观测数据 X 上。试图逆向解构出 Z [1]。这种操作。完美满足了 Locatello 定理的适用条件。SAE 没有任何将特定字典元素绑定到特定概念的归纳偏置（Inductive bias）。因此。它本质上就是在求解一个高度受限的无监督解缠结问题。

一旦确立了这一同构映射。只要目标流形维持着非线性的纠缠状态。且缺乏极端严苛的归纳偏置。任何试图将其逆向解构的尝试都将直接撞上盲系统辨识与非线性独立成分分析（Nonlinear ICA）的绝对高墙。Locatello 等人在 2019 年的研究中通过其核心定理 1 给出了一个无情的全局性数学证明。对于任意的生成模型。如果没有对模型和数据集施加特定的归纳偏置。无监督的解缠结学习在根本上是不可识别的（Fundamentally impossible）。

这与经典的 Hyvärinen 与 Pajunen (1999) 关于非线性 ICA 非唯一性的工作形成了致命的共鸣 [4]。在缺乏现实辅助假设下。从连续的非线性混合状态中提取独立成分。存在着一个无限的、连续的等价解族。

这构成了一个无条件信息论上界。它宣告了单纯扩展算力或升级网络架构（如使用 MLP 编码器或推理时优化）的徒劳。在那个不可数的高维流形上。存在无数种完全正交的非线性字典与特征铺砖策略。它们在数学上都能以完全相同的精度重构出同一组低维的激活观测值。那些 30% 重合率的孤独特征。是连续空间几何等价性的直接显现。不同的随机种子仅仅是在一个拥有无限自由度的不可识别解空间里。随机降落在了完全正交的局部山谷之中。

3 具体架构下的定量极限：L-NL 条件下的帕累托下界

在确立了无条件信息论封锁之后。我们退回到当前主流的线性-非线性 (L-NL) 架构中。给出一个可计算的定量下界。定义总误差为覆盖误差 $\epsilon_c(h)$ 与单义性误差 $\epsilon_m(h)$ 的线性组合。这份定量的判决建立在三个已被严格证明的局部物理约束之上。

第一道约束来自摊销间隙与受限秩。O'Neill 等人的定理 3.1 证明 [5]。任何采用 L-NL 编码器架构的稀疏自编码器其推断过程必然存在一个严格大于零的摊销间隙 [5]。由于编码器权重矩阵的秩最高被物理限制在观测维度 M 以内。它在代数上绝对无法无损恢复更高维度 N 的稀疏代码 [5]。这直接锁死了 SAE 的经验 Rademacher 复杂度。

第二道约束来自有限稀疏度下的流形干涉。Cui 等人的定理 4 指出 [6]。在特征未达到极端正交稀疏的现实环境下。重构误差的下界被一个结构性的干涉矩阵 $\mathcal{I} = W_p^\top W_p - I$ 所严格主导 [6]。简单的容量扩张无法抹除残差。必然导致真实特征的收缩与坍塌 [6]。

第三道约束来自子空间恢复与不相干性。Bhalla 等人的定理 1 规定。要实现流形的完美无损覆盖。字典基底必须保持绝对严格的 μ -不相干性。这要求满足极度严格的不等式 $\mu < 1/(2k-1)$ 以拒绝任何语义的混叠。

在巨大的容量逆差面前。算法唯一的代数解是主动破坏不相干性前提。字典中的基向量被迫发生偏转与扭曲。去同时承载多个真实特征的纠缠投影（局部铺砖与稀释）。在给定的置信度下。任何受限 L-NL 架构的 SAE 输出的特征字典其总误差 $\mathcal{E}_{min}$ 必然满足：

$$\mathcal{E}_{min} = \epsilon_c(h) + \lambda \epsilon_m(h) \geq C_0 \cdot \|\mathcal{I}\|_2 \cdot \kappa \cdot \Delta\mu$$

常数 C_0 是由带宽赤字定义的绝对物理约束 $C_0 = \max(0, 1 - \frac{M}{K \log(N/K)})$ 。 $\|\mathcal{I}\|_2$ 是流形干涉的谱范数。 κ 为内在曲率。 $\Delta\mu$ 则是几何上的不相干性破缺 $\max(0, \sqrt{\frac{L-M}{M(L-1)}} - \frac{1}{2k-1})$ 。

为了吞噬这庞大的极限误差 $\mathcal{E}_{min}$ 。SAE 被迫放弃部分字典元素的单义性。将其推入维度高达 $\mathcal{O}(L-M)$ 的过完备零空间内进行随机漂移。这使得重合率 ρ 的函数表现为：

$$\rho = 1 - \frac{C_0 \cdot \|\mathcal{I}\|_2 \cdot \kappa \cdot \Delta\mu}{L \cdot (1 - \tau)}$$

由于干涉矩阵谱范数 $\|\mathcal{I}\|_2$ 与流形内在曲率 κ 在实际大模型中难以被独立测量。我们不能将其视为精确的数值预言。然而。当代入 131K 字典的超大容量与 TopK 截断引发的几何破裂时（导致 $\Delta\mu$ 激增）。该下界公式在代数行为上与 Paulo 与 Belrose 观测到的 30% 重合率呈现出高度的定性一致（Qualitatively consistent）[1]。这诚实地证明了特征重合率的指数级坍塌不是训练噪声。而是受制于物理约束刚性化后的必然妥协。

4 本体论的重构与解释性范式的转移

这份分析报告完成了一次针对神经网络机制可解释性本体论的深度清创。

那份被期许的绝对真实的词汇表。在信息论的极限下是不存在的。SAE 所揭示的任何一组特征集合都不应该被教条地视为模型真正使用的穷尽清单。它仅仅是一种实用主义的分解。这要求我们对高维物理法则保持最高程度的敬畏。我们必须彻底放弃寻找那套唯一神圣代码的执念。接受一个更为流动的本体论框架。注视着这些连续不断的激活流。理解它们结构性的不完美。并在这些重叠的、非唯一的特征瓦片上。继续拼凑我们对这个世界运行法则的微小认知。

References

- [1] Paulo, G., & Belrose, N. (2025). Sparse Autoencoders Trained on the Same Data Learn Different Features. *arXiv preprint arXiv:2501.16615*.
- [2] Elhage, N., et al. (2022). Toy Models of Superposition. *Transformer Circuits Thread*.
- [3] Locatello, F., et al. (2019). Challenging Common Assumptions in the Unsupervised Learning of Disentangled Representations. *ICML*.
- [4] Hyvärinen, A., & Pajunen, P. (1999). Nonlinear independent component analysis: Existence and uniqueness results. *Neural Networks*.
- [5] O’Neill, C., Gumran, A., & Klindt, D. (2024). Compute Optimal Inference and Provable Amortisation Gap in Sparse Autoencoders. *arXiv preprint arXiv:2411.13117*.
- [6] Cui, J., Zhang, Q., Wang, Y., & Wang, Y. (2026). On the Limits of Sparse Autoencoders: A Theoretical Framework and Reweighted Remedy. *ICLR*.
- [7] Bhalla, U., et al. (2026). Do Sparse Autoencoders Capture Concept Manifolds? *arXiv preprint arXiv:2604.28119*.
- [8] Zheng, Y., Li, Z., Fan, S., Wilson, A. G., & Zhang, K. (2026). Diverse Dictionary Learning. *arXiv preprint arXiv:2604.17568*.