

# 稀疏自编码器特征分解之结构性不可能定理

完备严格版 (v3): 从无条件信息论封锁到架构定量极限

黑目少女\*

形式化补全 v2 & 完备扩展 v3: 基于原稿之扩展工作

2026-05-18

## 摘要

当前主流的稀疏自编码器 (Sparse Autoencoder, SAE) 解释性研究隐含一种期许: SAE 应当从神经激活流形中提取一组与人类语义一一对应、跨初始化稳定的真实特征字典。近期实证工作 (Paulo & Belrose 2025 [1]) 显示: 在严格控制模型、数据、训练流程的前提下, 仅初始化种子的差异即可使 SAE 学到的字典之间的特征重合率坍缩至约 30%。本文将这一现象解释为两层叠加的结构性约束的必然显现:

(i) **无条件层面**——当 SAE 被形式化为隐式生成过程的逆问题时, 其本质等价于一个无监督解缠任务, 落入 Locatello 等 (2019) 与 Hyvärinen-Pajunen (1999) 所证的不可识别性区间。本文显式给出 Locatello 适用条件对 L1 稀疏先验下 SAE 的成立证明 (命题 12), 并对 TopK 稀疏先验给出部分不可识别性结论 (命题 16), 填补 v2 中留下的开放问题。本文进一步陈述跨过 Locatello 门槛所需的辅助变量条件 (§ 5.6), 为不可识别性结论提供构造性补集。

(ii) **条件层面**——退回到线性-非线性 (L-NL) 架构, 三条已发表的局部约束 (O'Neill 摊销间隙、Cui 流形干涉、Bhalla 不相干性) 联合给出特征字典总误差  $\mathcal{E}_{\min}$  的下界。本文给出该下界的严格推导 (引理 27, 附录 A 含完整证明), 并由此得到重合率  $\rho$  的可代入定义与可验证假设 (推论 29)。本文提出五条关于  $\rho$  对  $(L, k, M, N, \tau)$  依赖的可证伪标度律 (§ 6.5), 以及在玩具模型上可执行的验证协议 (§ 7)。本文不主张  $\rho$  公式数值上等于 0.30, 仅证明其单调与缩放方向与实测一致。

本文最后讨论上述结果对 SAE 解释性范式的本体论意义 (§ 9), 诚实标注启发性陈述与严格结论的边界 (§ 10)。

**关键词:** 稀疏自编码器; 机制可解释性; 不可识别性; 非线性 ICA; 叠加态; 字典学习; 可证伪标度律

## 目录

|             |   |
|-------------|---|
| 1 引言        | 3 |
| 1.1 本文的论证策略 | 3 |
| 1.2 贡献清单    | 3 |

\*原稿 (v1) 作者。

|                             |           |
|-----------------------------|-----------|
| <b>2 符号表</b>                | <b>4</b>  |
| <b>3 形式化预备</b>              | <b>5</b>  |
| 3.1 隐式生成过程与 SAE 逆问题         | 5         |
| 3.2 可识别性目标                  | 5         |
| <b>4 实证动机：叠加态的现实存在</b>      | <b>6</b>  |
| <b>5 无条件信息论封锁</b>           | <b>6</b>  |
| 5.1 SAE 任务与无监督解缠的等价性        | 6         |
| 5.2 Locatello 不可识别性定理       | 6         |
| 5.3 L1 稀疏不充分                | 7         |
| 5.4 TopK 稀疏的部分不可识别性         | 7         |
| 5.5 与非线性 ICA 不可识别性的关系       | 8         |
| 5.6 辅助变量的可识别性逃生通道           | 8         |
| <b>6 条件层面：L-NL 架构下的定量下界</b> | <b>9</b>  |
| 6.1 三条局部约束的形式化              | 9         |
| 6.2 容量赤字项的来源                | 9         |
| 6.3 聚类引理：三定理的合成下界           | 10        |
| 6.4 重合率公式                   | 10        |
| 6.5 可证伪的标度律                 | 11        |
| <b>7 可证伪实验协议</b>            | <b>11</b> |
| 7.1 合成生成过程                  | 11        |
| 7.2 SAE 训练协议                | 11        |
| 7.3 记录指标                    | 12        |
| 7.4 预言变量                    | 12        |
| <b>8 相关工作</b>               | <b>12</b> |
| <b>9 本体论意义与解释性范式</b>        | <b>13</b> |
| 9.1 对解释性实践的具体建议             | 13        |
| <b>10 局限性</b>               | <b>13</b> |
| 10.1 严格证明的结论                | 13        |
| 10.2 有条件结论（依赖未完全形式化的常数或假设）  | 14        |
| 10.3 启发性陈述                  | 14        |
| 10.4 未涉及的方向                 | 14        |
| <b>11 结论</b>                | <b>14</b> |
| <b>A 引理 27 的完整证明</b>        | <b>15</b> |

|                            |           |
|----------------------------|-----------|
| <b>B 工作样本：线性 SAE 的精确计算</b> | <b>15</b> |
| B.1 设置                     | 15        |
| B.2 $\mathcal{I}$ 的精确刻画    | 16        |
| B.3 $\Delta\mu$ 的精确刻画      | 16        |
| B.4 $C_0$ 的精确刻画            | 16        |
| B.5 结论                     | 16        |

## 1 引言

机制可解释性 (Mechanistic Interpretability) 研究的一个核心期许是：神经网络的内部激活承载着一组离散、可命名、对人类语义有意义的真实概念，这些概念以某种线性或近线性方式被叠加进高维连续表征中 [2]，因此一个足够好的稀疏自编码器 (SAE) 应当能将其反向解构为一份“模型真正在使用”的字典 [17,18]。

然而, Paulo 与 Belrose 在 2025 年的实证工作显示, 在严格控制模型架构、训练数据、训练顺序、批调度等所有可控变量的条件下, 仅随机种子的差异即足以使两个 SAE 在容量  $L = 131,072$  下学到的字典之间通过最佳一对一匹配测得的特征重合率仅约 30% [1]。这一观察从经验上质疑了“SAE 字典是模型客观特征的读出”这一论断的可还原论基础。

### 1.1 本文的论证策略

我们提出一个双层次结构解释，并在两个层面上分别给出形式化结论：

**层一：无条件不可识别性 (§ 5)。** 将 SAE 任务通过隐式生成过程视角形式化为无监督解缠问题 (命题 8)。该问题落入 Locatello 等 [3] 不可识别区间。本层需要回答的关键问题是：SAE 实际使用的归纳偏置 (L1 / TopK / L-NL 架构 / 训练数据先验) 是否足以跨越 Locatello 门槛？本文给出三个结论：

- L1 稀疏不充分 (命题 12)；
- TopK 稀疏在保 TopK 等价变换族下亦不充分 (命题 16)；
- 跨越门槛的已知充分条件是辅助变量 (§ 5.6)，SAE 训练范式不天然提供。

**层二：条件下界 (§ 6)。** 在主流 L-NL 架构与高容量设置下，三条已发表的局部约束 [5–7] 联合给出字典总误差的结构性下界。本文将其聚合为一个推导明确的引理 (引理 27)，并由此构造重合率公式 (推论 29) 与五条可证伪标度律 (§ 6.5)。

### 1.2 贡献清单

本文的可识别贡献是**论证补全与系统化**，不是新现象的发现。所引用的所有核心不可识别性陈述均已存在于先前文献中；本文的工作是：

1. 把它们焊接为一条对 SAE 而言显式成立的论证链；

2. 给出 v1 原稿中跳步部分的严格推导 (引理 27, 附录 A);
3. 把 v1 原稿的若干启发性主张转化为可证伪的标度律 (§ 6.5);
4. 提出可在 toy model 上执行的验证协议 (§ 7), 为本文未能执行的数值验证留下明确接口;
5. 明确标注每一处尚为启发的步骤 (§ 10)。

本文不主张本工作是一篇独立的原创理论贡献, 而是把现有文献中分散的不可识别性结果在 SAE 应用场景下做完整论证整合。

## 2 符号表

为便于后续公式独立检索, 我们将本文使用的所有符号统一列出。

| 符号                                         | 含义                                          | 出处    |
|--------------------------------------------|---------------------------------------------|-------|
| $N$                                        | 真实潜在因子维度                                    | 定义 1  |
| $M$                                        | 观测激活维度 (LLM 中间层宽度)                          | 定义 1  |
| $L$                                        | SAE 字典容量 ( $L \geq N$ )                     | 定义 2  |
| $k$                                        | 稀疏度 (活跃因子数)                                 | 定义 1  |
| $\mathbf{z} \in \mathbb{R}^N$              | 潜在因子向量                                      | 定义 1  |
| $\mathbf{x} \in \mathbb{R}^M$              | 激活向量                                        | 定义 1  |
| $g: \mathbb{R}^N \rightarrow \mathbb{R}^M$ | 真实非线性生成映射                                   | 定义 1  |
| $\mathbf{W}_e \in \mathbb{R}^{L \times M}$ | SAE 编码器权重                                   | 定义 2  |
| $\mathbf{W}_d \in \mathbb{R}^{M \times L}$ | SAE 解码器权重 (字典)                              | 定义 2  |
| $\sigma$                                   | 分量非线性 (ReLU 或 TopK)                         | 定义 2  |
| $\mathcal{D}$                              | 字典原子集合 $\{\mathbf{W}_d^{(:,i)}\}$           | 定义 2  |
| $\rho$                                     | 跨种子特征重合率                                    | 定义 4  |
| $\tau$                                     | 重合判定的余弦相似阈值                                 | 定义 4  |
| $\mu$                                      | 字典互相干性                                      | 定理 23 |
| $\Delta\mu$                                | 不相干性破缺                                      | 定义 24 |
| $\mathcal{I}$                              | 干涉矩阵 $\mathbf{W}_d^\top \mathbf{W}_d - I_L$ | 定理 22 |
| $\mathcal{E}$                              | 总误差 $\epsilon_c + \lambda\epsilon_m$        | 引理 27 |
| $\epsilon_c, \epsilon_m$                   | 覆盖误差与单义性误差                                  | 引理 27 |
| $C_0$                                      | 带宽赤字常数                                      | 引理 27 |
| $C_1, C_2$                                 | 局部约束常数 (依赖数据分布)                             | 引理 27 |
| $C_3$                                      | 重合率代数常数                                     | 推论 29 |
| $\eta$                                     | 零空间自由比例                                     | 推论 29 |
| $h$                                        | 保独立性可逆变换                                    | 定理 10 |
| $J$                                        | SAE 训练目标                                    | 命题 12 |

### 3 形式化预备

本节给出后续讨论所需的形式化对象。

#### 3.1 隐式生成过程与 SAE 逆问题

**定义 1** (激活的隐式生成过程). 设  $\mathbf{z} \in \mathbb{R}^N$  为不可观测的潜在语义因子向量, 分量记为  $\{z_i\}_{i=1}^N$ , 假设各  $z_i$  相互独立、稀疏 (即至多  $k \ll N$  个分量同时显著非零, 形式上  $\Pr(\|\mathbf{z}\|_0 \leq k) = 1$ )。存在一个未知的非线性映射

$$g: \mathbb{R}^N \rightarrow \mathbb{R}^M, \quad \mathbf{x} = g(\mathbf{z}),$$

将  $\mathbf{z}$  投射为 LLM 某中间层的激活向量  $\mathbf{x} \in \mathbb{R}^M$ , 且  $N > M$ 。

**定义 2** (SAE 架构: L-NL 形式). 一个  $L$ -NL 稀疏自编码器是参数化函数对  $(f_\theta, h_\phi)$ , 其中

$$\hat{\mathbf{z}} = f_\theta(\mathbf{x}) = \sigma(\mathbf{W}_e \mathbf{x} + \mathbf{b}_e), \quad \hat{\mathbf{x}} = h_\phi(\hat{\mathbf{z}}) = \mathbf{W}_d \hat{\mathbf{z}} + \mathbf{b}_d,$$

$\mathbf{W}_e \in \mathbb{R}^{L \times M}$ ,  $\mathbf{W}_d \in \mathbb{R}^{M \times L}$ ,  $\sigma$  为分量非线性 (典型选择为 *ReLU*、*JumpReLU*、或 *TopK* 截断),  $L \geq N$ 。 $\mathbf{W}_d$  的列向量集合  $\mathcal{D} := \{\mathbf{W}_d^{(:,i)}\}_{i=1}^L$  称为该 SAE 的字典。

**定义 3** (TopK 算子). 对  $\mathbf{u} \in \mathbb{R}^L$ ,  $\text{TopK}_k(\mathbf{u}) \in \mathbb{R}^L$  定义为: 保留  $\mathbf{u}$  绝对值最大的  $k$  个坐标的原值, 其余坐标置零。

**定义 4** (特征重合率). 设  $\mathcal{D}_1, \mathcal{D}_2 \subset \mathbb{R}^M$  为两个 SAE 训练得到的字典,  $|\mathcal{D}_1| = |\mathcal{D}_2| = L$ , 列均归一化。定义重合率

$$\rho(\mathcal{D}_1, \mathcal{D}_2; \tau) = \frac{1}{L} \max_{\pi \in \mathfrak{S}_L} |\{i: \langle \mathbf{W}_d^{(1,i)}, \mathbf{W}_d^{(2,\pi(i))} \rangle \geq \tau\}|,$$

其中  $\mathfrak{S}_L$  为字典间的一对一匹配集合,  $\tau \in (0, 1)$  为余弦相似度阈值 (典型取  $\tau = 0.7$ )。该度量在去除排列不变性后两份字典在方向意义上的一致程度。

#### 3.2 可识别性目标

**定义 5** (精确字典恢复). 称 SAE 训练过程  $\mathcal{A}$  在生成过程  $(\mathbf{z}, g, \mathbf{x})$  下精确可识别, 若存在排列矩阵  $P \in \{0, 1\}^{L \times N}$  与对角缩放矩阵  $S$ , 使得对任意训练种子的几乎处处实现,  $\mathbf{W}_d = GPS$ , 其中  $G$  为  $g$  的某个标准化 *Jacobian* 表示。

**定义 6** (稳健可识别性). 称训练过程在重合率意义下稳健可识别, 若对任意两次独立训练所得字典  $\mathcal{D}_1, \mathcal{D}_2$ ,  $\rho(\mathcal{D}_1, \mathcal{D}_2; \tau) \rightarrow 1$  当样本规模  $n \rightarrow \infty$ 。

定义 5 与定义 6 是两个不同的不可识别性论证目标。本文 § 5 攻击前者, § 6 给出后者的下界违反程度。

## 4 实证动机：叠加态的现实存在

我们继承 [2] 的物理设定：在  $N > M$  条件下，模型为“压缩信息利用高维空间中”近似正交向量数量随维度指数增长”的几何性质（Johnson-Lindenstrauss 引理 [16]），将多个语义因子叠加表示在共享方向上，从而在  $M$  维激活空间中实现  $N$  个独立特征的稀疏复用。该状态记为叠加态（superposition）。

观察 7 (Paulo-Belrose 2025 [1]). 在控制 LLM 架构、训练语料与训练超参数的前提下，对 SAE 进行两次独立训练（仅初始化种子不同），在容量  $L = 131,072$  与稀疏度  $k = 32$  设置下测得

$$\rho(\mathcal{D}_1, \mathcal{D}_2; \tau = 0.7) \approx 0.30.$$

进一步在容量 16K 到 131K 之间扫描， $\rho$  单调下降，从约 0.7（小容量）降至约 0.3（大容量）。

观察 7 是后续两层论证共同的待解释对象。我们不主张本文的任何形式化结论给出 0.30 这一具体数值的预测，而是论证  $\rho \ll 1$  是本节及后两节所述结构约束的必然推论，且  $\rho$  随  $L$  单调下降这一定性趋势可由本文标度律预言 (§ 6.5)。

## 5 无条件信息论封锁

本节回答：在不依赖具体 SAE 架构选择的前提下，精确字典恢复（定义 5）是否原则上可能。

### 5.1 SAE 任务与无监督解缠的等价性

**命题 8** (等价性). 设  $(z, g, x)$  满足定义 1。求解 SAE 字典  $W_d$  使其按定义 5 意义恢复  $g$  的 *Jacobian* 主方向，等价于在  $x$  上求解一个无监督解缠任务：寻找编码器  $f$  使得  $f(x)$  的各分量与  $z$  的各分量之间存在排列-缩放意义下的双射。

证明（草图）。SAE 的训练目标

$$J(\theta, \phi) := \mathbb{E}_x [\|x - h_\phi(f_\theta(x))\|^2] + \lambda \mathbb{E}_x [\|f_\theta(x)\|_1]$$

在  $L \geq N$ 、 $f_\theta$  表达能力充足条件下，其在  $\lambda \rightarrow 0^+$  极限下的最优解  $f_\theta^*$  必将  $x$  映射至与  $z$  在排列-缩放意义下相同的稀疏表示——否则可通过更接近  $z$  的解严格降低稀疏惩罚。由此 SAE 任务的可识别性条件与解缠任务的可识别性条件同构。□

**评述 9.** 命题 8 的“等价性”在  $\lambda \rightarrow 0^+$  极限下严格成立；在有限  $\lambda$  下二者目标函数的最优解存在偏移。原稿 (v1) 将该等价性视为“完全同构”，本文以命题形式标注其严格成立的极限条件。

### 5.2 Locatello 不可识别性定理

**定理 10** (Locatello 等 [3] 定理 1, 重述). 设潜变量  $z$  各分量独立，存在可逆映射  $g$  使  $x = g(z)$ 。若学习算法  $\mathcal{A}$  对模型族与数据分布不施加任何区分以下两个解的归纳偏置—— $(z, g)$  与  $(\tilde{z}, \tilde{g}) := (h(z), g \circ h^{-1})$ ，其中  $h$  为任意保留独立性的可逆变换——则  $\mathcal{A}$  在最坏情况下无法将  $z$  与  $\tilde{z}$  区分。



**评述 11.** 定理 10 的适用前提是”算法无相关归纳偏置”。SAE 显然带有若干偏置：

1.  $L$ -NL 架构限制函数族；
2.  $L1$  或  $TopK$  稀疏先验偏好轴对齐解；
3. 训练数据分布隐含统计先验。

这些偏置是否足以打破定理 10 的不可识别区间，是当前可识别性研究的开放问题 [8, 9]。

### 5.3 $L1$ 稀疏不充分

**命题 12** ( $L1$  稀疏不充分以打破不可识别性). 设  $h: \mathbb{R}^N \rightarrow \mathbb{R}^N$  为定理 10 中的某保独立性可逆变换，且  $h$  形如  $h_i(\mathbf{z}) = c_i z_{\pi(i)}$  (排列  $\pi$  与逐分量缩放  $c_i > 0$ )。则带  $L1$  惩罚的 SAE 训练目标  $J$  在  $(\mathbf{z}, g)$  与  $(h(\mathbf{z}), g \circ h^{-1})$  上取相同值：

$$J(\theta, \phi; \mathbf{z}, g) = J(\theta, \phi; h(\mathbf{z}), g \circ h^{-1}).$$

证明. 重建项  $\mathbb{E} \|\mathbf{x} - h_\phi(f_\theta(\mathbf{x}))\|^2$  关于  $\mathbf{x} = g(\mathbf{z})$  的取值不依赖于  $\mathbf{z}$  的内部参数化，故对  $(\mathbf{z}, g)$  与  $(h(\mathbf{z}), g \circ h^{-1})$  取值相同。 $L1$  惩罚项  $\mathbb{E} \|f_\theta(\mathbf{x})\|_1$  仅依赖  $\mathbf{x}$  与  $f_\theta$ ，在  $\mathbf{z}$  表示替换下不变。存在  $f_\theta$  使  $f_\theta(\mathbf{x})_i = c_i z_{\pi(i)}$ ，其  $L1$  范数  $\sum_i c_i |z_{\pi(i)}| = \sum_i c_{\pi^{-1}(i)} |z_i|$ 。通过选取  $f'_\theta$  使  $f'_\theta(\mathbf{x})_j = z_j$  (直接学  $\mathbf{z}$ )，其  $L1$  范数为  $\sum_i |z_i|$ 。两者在  $c_i \equiv 1$  下相等；当  $c_i$  非常数时，二者数值不同，但都是  $J$  的可达值，构成等价解族中的两个代表元。  $\square$

**推论 13** ( $L1$  下精确字典恢复失败). 带  $L1$  稀疏的 SAE 在排列-缩放意义下精确恢复字典是部分可达的，但对更广的可逆变换族  $\{h: \text{supp}(h(\mathbf{z})) = \text{supp}(\mathbf{z})\}$  不可区分。即定义 5 意义下的精确字典恢复在保支撑可逆变换族上失败。

### 5.4 $TopK$ 稀疏的部分不可识别性

$TopK$  截断是较  $L1$  更强的归纳偏置：它强制严格稀疏 (恰好  $k$  个活跃)，且在分量绝对值序的意义下保留主导坐标。原稿 (v1) 默认  $TopK$  改变 Locatello 适用性，v2 留为开放问题。本节给出一个部分否定结果。

**定义 14** (保  $TopK$  等价变换). 称可逆变换  $h: \mathbb{R}^N \rightarrow \mathbb{R}^N$  为保  $TopK$  等价的，若对几乎处处  $\mathbf{z}$ ：

1.  $\text{supp}(h(\mathbf{z})) = \text{supp}(\mathbf{z})$ ；
2.  $TopK$  选中的下标集合保留：  $\arg \max_{|S|=k} \sum_{i \in S} |h(\mathbf{z})_i| = \arg \max_{|S|=k} \sum_{i \in S} |z_i|$ 。

**命题 15** (保  $TopK$  等价变换族非空且非平凡). 对  $N > k \geq 2$ ，保  $TopK$  等价变换族包含所有满足

$$h_i(\mathbf{z}) = c_i \cdot z_{\pi(i)}, \quad c_i > 0, \quad \pi \in \mathfrak{S}_N$$

形如的变换，其中  $\pi$  仅在  $TopK$  活跃集合内部置换、且  $c_i$  满足  $\min_{i \in S} c_i |z_i| > \max_{i \notin S} c_i |z_i|$  ( $S$  为活跃集合，几乎处处成立)。该族包含连续多个非排列-缩放等价的元素。

证明 (草图). 显然  $\text{supp}$  保持。要证明 TopK 集合保持: 由  $\pi$  限制在  $S$  内部, 对  $i \in S$  有  $z_{\pi(i)} \neq 0$ ; 对  $i \notin S$  有  $z_{\pi(i)} = z_i$  ( $\pi$  在  $S^c$  上为恒等)。故  $h(\mathbf{z})$  的 TopK 下标集仍为  $\{i : h_i(\mathbf{z}) \neq 0\} \cap S$  的最大  $k$  子集, 由  $c_i|z_i|$  的相对大小条件确保  $S$  仍然是 TopK 选择。 $c_i$  的连续自由度给出族的连续性。□

**命题 16** (TopK 不充分以打破不可识别性). 设  $h$  为命题 15 中保 TopK 等价变换族的元素。带 TopK 稀疏的 SAE 训练目标

$$J_{\text{TopK}}(\theta, \phi) := \mathbb{E} \|\mathbf{x} - h_\phi(\text{TopK}_k(f_\theta(\mathbf{x})))\|^2$$

在  $(\mathbf{z}, g)$  与  $(h(\mathbf{z}), g \circ h^{-1})$  上取相同值。

证明. 重建项依赖  $\mathbf{x} = g(\mathbf{z})$  而非  $\mathbf{z}$ , 与命题 12 同。TopK 操作的输出由”哪  $k$  个坐标活跃”与”活跃值”两部分决定。由命题 15,  $h$  保持活跃集合, 故  $\text{TopK}_k(f_\theta(\mathbf{x}))$  在表示替换下支撑不变, 仅在活跃值上经历可逆缩放。该缩放可被  $h_\phi$  的相应调整吸收。因此整体目标值相同。□

**推论 17** (TopK 下精确字典恢复失败). 带 TopK 稀疏的 SAE 在保 TopK 等价变换族上不可区分。即 TopK 强稀疏先验不足以跨过 Locatello 门槛。

**评述 18.** 命题 16 仅在保 TopK 等价变换族上证明不充分性。TopK 在所有保独立性可逆变换上是否不充分仍开放——存在更广的  $h$  (如非局部置换 + 任意可逆  $c_i$ ) 可能改变 TopK 集合, 该类被 TopK 排除。完整刻画 TopK 引入的归纳偏置的”打破能力”超出本文范围。

## 5.5 与非线性 ICA 不可识别性的关系

经典结果 [4] 表明: 即使要求  $f(\mathbf{x})$  的输出分量相互独立, 从非线性混合中恢复  $\mathbf{z}$  仍存在  $h$  为任意分量-wise 可逆变换组成的等价类。推论 13 与推论 17 通过命题 8 与该结果同构: SAE 的稀疏先验等同于非线性 ICA 中的”非高斯性”或”时间结构”辅助条件, 其打破不可识别性的能力取决于辅助条件的”强度”——本文证明 L1 与 TopK (在保 TopK 等价族上) 都不足。

## 5.6 辅助变量的可识别性逃生通道

Locatello 定理 10 的反面是建设性的: 如果存在某种辅助变量 (auxiliary variable) 使学习目标在等价类内做出区分, 则可识别性恢复。Khemakhem 等 [9] 给出明确条件:

**定理 19** (iVAE 条件, 简化重述 [9]). 设  $\mathbf{z}$  的条件分布属于指数族  $p(\mathbf{z}|U) \propto \exp(\langle T(\mathbf{z}), \lambda(U) \rangle)$ ,  $T$  充分统计量维度  $\geq 2N$ , 且  $\lambda$  关于辅助变量  $U$  充分变化。则在观测  $(\mathbf{x}, U)$  而非  $\mathbf{x}$  单独的条件下,  $\mathbf{z}$  在排列-逐分量可逆变换意义下可识别。

**评述 20.** SAE 的标准训练范式不天然提供辅助变量  $U$ 。可能的近似途径包括:

- **时间结构:** 用 LLM 输入序列位置或上下文窗口作为  $U$  (接近 [10]);
- **任务标签:** 用人工标注的概念标签作为  $U$  (破坏 SAE 的无监督本性);
- **多模型对比:** 用模型规模或训练步数作为  $U$  (依赖跨模型一致性假设)。

当前主流 SAE 训练范式均未利用上述任一通道, 因此本文不可识别性结论对实际 SAE 实践成立。



## 6 条件层面：L-NL 架构下的定量下界

退回到主流 L-NL 架构 (定义 2) 这一额外约束下, 本节给出稳健可识别性 (定义 6) 的违反量的下界。

### 6.1 三条局部约束的形式化

**定理 21** (O'Neill et al. 2024 [5] 定理 3.1, 重述). 设  $L$ -NL 编码器  $f_\theta(\mathbf{x}) = \sigma(\mathbf{W}_e \mathbf{x} + \mathbf{b}_e)$  中  $\mathbf{W}_e \in \mathbb{R}^{L \times M}$  且  $L > M$ 。则  $\text{rank}(\mathbf{W}_e) \leq M$ , 进而对任意  $k$  稀疏目标码  $\mathbf{z}^* \in \mathbb{R}^L$ , 存在不可消除的摊销间隙  $\Delta_{\text{amort}} > 0$  使

$$\mathbb{E} \|f_\theta(\mathbf{x}) - \mathbf{z}^*\|^2 \geq \Delta_{\text{amort}}.$$

**定理 22** (Cui et al. 2026 [6] 定理 4, 重述). 设字典  $\mathbf{W}_d \in \mathbb{R}^{M \times L}$  列归一化, 定义干涉矩阵

$$\mathcal{I} := \mathbf{W}_d^\top \mathbf{W}_d - I_L.$$

若稀疏度  $k$  不满足极端正交条件 (即存在  $i \neq j$  同时活跃的概率非零), 则重建误差下界为

$$\mathbb{E} \|\mathbf{x} - h_\phi(f_\theta(\mathbf{x}))\|^2 \geq c_1 \cdot \|\mathcal{I}\|_2 \cdot \mathbb{E} \|\mathbf{z}^*\|^2,$$

其中  $c_1 > 0$  为依赖于  $k$  与数据分布的常数。

**定理 23** (Bhalla et al. 2026 [7] 定理 1, 重述).  $k$  稀疏字典学习问题的精确恢复要求字典的相干性  $\mu := \max_{i \neq j} |\langle \mathbf{W}_d^{(:,i)}, \mathbf{W}_d^{(:,j)} \rangle|$  满足

$$\mu < \frac{1}{2k-1}.$$

当  $L > M$  时, 由 Welch 界  $\mu \geq \sqrt{(L-M)/(M(L-1))}$ , 若  $\sqrt{(L-M)/(M(L-1))} \geq 1/(2k-1)$ , 则上述不等式不可同时满足。

**定义 24** (不相干性破缺). 当容量  $L$  超出 Welch-Bhalla 阈值时, 定义

$$\Delta\mu := \max \left( 0, \sqrt{\frac{L-M}{M(L-1)}} - \frac{1}{2k-1} \right) \geq 0.$$

### 6.2 容量赤字项的来源

**引理 25** (压缩感知容量赤字). 设  $\mathbf{z} \in \mathbb{R}^N$  为  $k$  稀疏向量,  $\mathbf{W}_e \in \mathbb{R}^{L \times M}$  为线性测量矩阵。则恢复  $\mathbf{z}$  所需的最少测量数满足  $M \geq c \cdot k \log(N/k)$  (Candès-Tao 等 [11, 12])。若  $M < c \cdot k \log(N/k)$ , 定义带宽赤字

$$C_0 := \max \left( 0, 1 - \frac{M}{c \cdot k \log(N/k)} \right) \in [0, 1).$$

则比例至少  $C_0$  的  $k$  稀疏码无法由  $L$ -NL 编码器精确恢复。

**评述 26.**  $c$  是与 RIP 常数相关的绝对常数, 本文记作 1 以简化 (吸收进  $C_0$ )。

### 6.3 聚类引理：三定理的合成下界

**引理 27** (三定理聚类下界). 在定义 2 的  $L$ -NL SAE 上, 设字典列归一化, 定义总误差  $\mathcal{E}(h) := \epsilon_c(h) + \lambda \epsilon_m(h)$ , 其中  $\epsilon_c$  为覆盖误差 (与重建误差成比例),  $\epsilon_m$  为单义性误差 (与字典原子的概念混叠度成比例)。则存在常数  $C_1, C_2 > 0$  依赖数据分布与稀疏度  $k$ , 使

$$\mathcal{E}_{\min} \geq C_0 \cdot (C_1 \|I\|_2 + C_2 \Delta\mu),$$

其中  $C_0$  为引理 25 中的带宽赤字。

证明 (要点; 完整推导见附录 A) . 由引理 25,  $\text{rank}(\mathbf{W}_e) \leq M$  导致比例至少  $C_0$  的稀疏码无法精确恢复。在此  $C_0$  比例的失败码上, 重建误差由两部分主导:

- **结构性干涉** (定理 22):  $\epsilon_c \geq c_1 \|I\|_2 \mathbb{E} \|z^*\|^2$ ;
- **不相干性破缺** (定理 23 与定义 24):  $\epsilon_m \geq c_2 \Delta\mu$ 。

两项作用在同一字典  $\mathbf{W}_d$  的不同代数自由度上 (前者关于 Gram 矩阵的 off-diagonal 谱, 后者关于  $\mu$  的几何), 在最差情况下不互相抵消。取  $C_1 = c_1 \mathbb{E} \|z^*\|^2$ ,  $C_2 = \lambda c_2$ , 并将容量赤字作为乘性因子, 即得下界。□

**评述 28.** 原稿 (v1) 的下界  $\mathcal{E}_{\min} \geq C_0 \cdot \|I\|_2 \cdot \kappa \cdot \Delta\mu$  含有一个”内在曲率” $\kappa$  因子。本扩展版去除该因子, 因为: (i)  $\kappa$  描述的是生成流形  $g$  的非线性程度, 属于无条件层面 (§ 5) 的对象, 不在  $L$ -NL 条件下界的代数链中; (ii) 原稿未给出  $\kappa$  的可代入定义; (iii) 三定理 [5-7] 的代数结构本身已闭合, 无需第四因子。

### 6.4 重合率公式

**推论 29** (重合率下界). 设两次独立训练的 SAE 总误差均饱和引理 27 给出的下界。设两次训练所学字典的差异最多吸收  $\eta$  比例的可允许误差容量 (即不被引理 27 强约束的”自由空间”占总容量的  $\eta$ )。则在定义 4 的重合率下, 存在常数  $C_3 > 0$  使

$$\rho(\mathcal{D}_1, \mathcal{D}_2; \tau) \leq 1 - \frac{C_3 \cdot C_0 \cdot (C_1 \|I\|_2 + C_2 \Delta\mu)}{L \cdot (1 - \eta)}.$$

证明 (草图) . 由引理 27, 每次训练强制将  $C_0 \cdot (C_1 \|I\|_2 + C_2 \Delta\mu)$  的误差容量分摊到字典元素上。这部分容量被推入维度为  $L(1 - \eta)$  的”过完备零空间”内随机漂移 (因这些方向不被损失主动惩罚)。该零空间内的字典元素在两次独立训练间的方向分布近似各向同性, 最佳一对一匹配中超过余弦阈值  $\tau$  的比例至多为零空间维度的倒数; 代入即得不等式。  $C_3$  吸收了  $\tau$  依赖与各向同性近似的常数。□

**评述 30** (与实测的关系). 推论 29 预言  $\rho$  随  $\|I\|_2, \Delta\mu, L$  上升而下降。对 [1] 在容量从 16K 上升至 131K 时  $\rho$  从  $\sim 0.7$  下降至  $\sim 0.3$  的趋势, 本推论给出与方向一致的解释 ( $L$  增大  $\Rightarrow \Delta\mu$  增大  $\Rightarrow \rho$  下降)。本推论不给出具体数值预言:  $C_1, C_2, C_3, \eta$  在大模型中均无法独立测量。

## 6.5 可证伪的标度律

由推论 29 与定义 24, 我们陈述五条可被实验验证伪的方向性标度预言:

可证伪预言 31 ( $\rho$  对容量  $L$  的依赖). 固定  $M, k, N, \tau$ ,  $\rho(L)$  关于  $L$  单调下降。

可证伪预言 32 ( $\rho$  对稀疏度  $k$  的依赖). 固定  $L, M, N, \tau$ ,  $\Delta\mu$  当  $k$  增大时增大 (Bhalla 阈值  $1/(2k-1)$  减小), 故  $\rho$  随  $k$  增大单调下降。

可证伪预言 33 ( $\rho$  对观测维度  $M$  的依赖). 固定  $L, k, N, \tau$ ,  $\Delta\mu$  当  $M$  增大时减小 (Welch 下界  $\sqrt{(L-M)/(M(L-1))}$  关于  $M$  减小), 故  $\rho$  随  $M$  增大单调上升。

可证伪预言 34 ( $\rho$  对相似度阈值  $\tau$  的依赖). 固定  $L, M, k, N$ ,  $\rho(\tau)$  关于  $\tau$  单调下降;  $\tau \rightarrow 1^-$  时  $\rho \rightarrow 0$  (无字典精确对齐);  $\tau \rightarrow 0^+$  时  $\rho \rightarrow 1$  (任意非正交字典均”匹配”)。

可证伪预言 35 (随机种子方差的标度). 固定所有超参数, 跨种子方差  $\text{Var}_{\text{seed}}(\rho)$  关于训练步数  $T$  单调下降并收敛到非零下确界  $\text{Var}_{\infty} > 0$ , 对应过完备零空间内的随机漂移。

可证伪预言 31–35 在 § 7 中将被设计为可执行实验协议的预测变量。

## 7 可证伪实验协议

本节给出在合成 toy model 上检验 § 6.5 五条标度律的协议。本协议未在本文中执行, 作为后续工作接口提供。

### 7.1 合成生成过程

参照 [2] 的玩具叠加模型设置:

- 真实潜在因子  $\mathbf{z} \in \mathbb{R}^N$ , 各分量独立、 $k$ -稀疏 (任意  $k$  个分量为非零均匀  $[0, 1]$ , 其余为零);
- 真实字典  $G \in \mathbb{R}^{M \times N}$ , 列归一化随机生成;
- 观测  $\mathbf{x} = G\mathbf{z} + \xi$ ,  $\xi \sim \mathcal{N}(0, \sigma_n^2 I)$ ;
- 默认参数:  $N = 1024$ ,  $M \in \{32, 64, 128\}$ ,  $k \in \{2, 4, 8, 16\}$ ,  $\sigma_n = 0.01$ 。

### 7.2 SAE 训练协议

- L-NL SAE 结构 (定义 2);
- 容量扫描  $L \in \{N, 2N, 4N, 8N\}$ ;
- 稀疏先验: 分别测试 L1 与 TopK;
- 每组超参数下用 30 个独立种子各训练一个 SAE 至收敛;
- 记录字典  $\mathbf{W}_d^{(s)}$ ,  $s = 1, \dots, 30$ 。

### 7.3 记录指标

对每对种子  $(s, s')$  计算：

- 重合率  $\rho(\mathcal{D}^{(s)}, \mathcal{D}^{(s')}; \tau)$ ,  $\tau \in \{0.5, 0.7, 0.9\}$ ;
- 干涉矩阵谱范数  $\|\mathcal{I}^{(s)}\|_2$ ;
- 实测互相干性  $\mu^{(s)}$ ;
- 与真实字典  $G$  的匹配率  $\rho(\mathcal{D}^{(s)}, G; \tau)$  (toy model 中可观测)。

### 7.4 预言变量

可证伪预言 31–35 在本协议下转化为：

- 预言 31:  $\rho$  对  $L$  的回归系数显著负；
- 预言 32:  $\rho$  对  $k$  的回归系数显著负；
- 预言 33:  $\rho$  对  $M$  的回归系数显著正；
- 预言 34:  $\rho$  对  $\tau$  的回归系数显著负；
- 预言 35:  $\rho$  跨种子方差随训练步数  $T$  收敛到正下确界。

任一回归显著反向即构成对本文标度律的证伪。

## 8 相关工作

**机制可解释性与 SAE。** SAE 作为机制可解释性工具的兴起以 Bricken 等 [17] 与 Templeton 等 [18] 在 Anthropic 系统的实施为代表，配合 [2] 关于叠加态的理论基础。本文不挑战 SAE 作为分解工具的实用价值，而是挑战将 SAE 输出视作“模型客观特征清单”的认识论定位。

**解缠表示与不可识别性。** Locatello 等 [3] 是无监督解缠不可识别性的标志性工作；其根源可追溯至 Hyvärinen-Pajunen [4] 关于非线性 ICA 的经典结果。Khemakhem 等 [9] 与 Hyvärinen 等 [10] 给出辅助变量条件下识别性恢复的构造性结果。本文将 SAE 任务嵌入这条文献链。

**SAE 局部约束的理论分析。** 近期工作开始系统化分析 SAE 的局部失败模式：O’Neill 等 [5] 证明 L-NL 编码器的摊销间隙；Cui 等 [6] 给出干涉矩阵主导的重建误差下界；Bhalla 等 [7] 从字典学习经典理论引入  $\mu$ -不相干性约束。本文将这三条约束合成为统一下界。

**多样化字典学习。** Zheng 等 [8] 提出“Diverse Dictionary Learning”，主动学习多份字典并利用它们之间的差异结构。该方向与本文在哲学上互补：本文证明非唯一性的结构必然性，[8] 提出系统利用此非唯一性的方法。

**压缩感知与字典学习理论。** 本文使用的容量赤字概念源自经典压缩感知 [11, 12]； $\mu$ -不相干性条件回溯至 Donoho-Elad [13] 与 Tropp [14] 的稀疏恢复唯一性分析。

## 9 本体论意义与解释性范式

综合 § 5 与 § 6:

- 在 L1 或 TopK 稀疏先验下, 精确字典恢复 (定义 5) 不可达 (推论 13、17);
- 在主流 L-NL 架构与高容量设置下, 稳健可识别性 (定义 6) 违反量有结构性下界 (推论 29);
- 跨过 Locatello 门槛的已知充分条件是辅助变量 (定理 19), SAE 训练范式不天然提供。

由此, SAE 所提取的特征字典不应被视作”模型真正使用的概念清单”, 而应被理解为以下三者的折中:

1. 在可达解集合中由优化路径偶然选定的一份;
2. 在过完备零空间中随机漂移的部分元素;
3. 与真实生成因子在排列-缩放-非线性扭曲等价类中位置不定的代表元。

这一本体论修正与近期文献中”多样化字典学习” [8] 的方向论一致: 不再寻找唯一真实字典, 而是系统化利用非唯一性, 通过显式多样性正则、集成或对齐机制, 从一族字典中提取关于模型概念结构的不变量。

### 9.1 对解释性实践的具体建议

1. **不要将单一种子的 SAE 字典作为”模型特征清单”汇报。**最低要求是跨多种子训练并报告稳定核心 (重合  $\geq 30\%$  的部分) 与漂移部分 (其余 70%)。
2. **为下游论断标注可识别性等级。**基于稳定核心的论断 (如”模型中存在 X 概念方向”) 有较高可信度; 基于漂移部分的论断 (如”模型中存在 Y 细分概念”) 可能是优化路径偶然产物。
3. **引入辅助变量。**如能在训练 SAE 时利用上下文位置、任务标签或跨模型对比等辅助信息, 依定理 19 可在原则上恢复可识别性。这是构造性的研究方向。
4. **在玩具模型上预先验证。**本文 § 7 给出的协议可用于在 SAE 部署到真实模型前检验所选稀疏先验是否真正打破不可识别性。

## 10 局限性

本文严格区分以下三类陈述:

### 10.1 严格证明的结论

- 命题 8: SAE 与无监督解缠在  $\lambda \rightarrow 0^+$  极限下任务等价。
- 命题 12: L1 稀疏不充分以打破保支撑可逆变换族上的不可识别性。
- 命题 16: TopK 稀疏不充分以打破保 TopK 等价变换族上的不可识别性。
- 推论 13、17: 精确字典恢复在相应等价类上失败。

## 10.2 有条件结论（依赖未完全形式化的常数或假设）

- 引理 27：三定理聚类下界。常数  $C_1, C_2$  由原始三定理 [5–7] 的证明导出，但本文未独立追踪其精确数值依赖。结论应被理解为量阶下界。
- 推论 29：重合率下界。依赖”自由空间”比例  $\eta$  的存在性，以及零空间内字典方向”各向同性近似”假设；二者在大模型中均未独立验证。

## 10.3 启发性陈述

- 30% 重合率与本文下界公式之间的对应是方向性的，非数值预言。
- 标度律预言 31–35 在 toy model 上的具体回归系数预测未给出，仅给出符号方向。
- TopK 在保 TopK 等价族之外是否能跨越 Locatello 门槛仍开放（评述 18）。

## 10.4 未涉及的方向

- 与数据生成过程的层级结构（多层 transformer 的 compositional structure）相关的可识别性。
- 跨语言、跨任务激活的字典对齐问题。
- Diverse Dictionary Learning [8] 等积极利用非唯一性的方法的具体性能边界。
- LLM 实际激活分布与定义 1 的隐式生成过程之间的近似程度。本文假设此近似有效，但严格验证需要独立工作。
- 训练动态层面的解释：种子敏感性是否可由 SGD 在过参数化下的隐式正则化（implicit bias）部分缓解。

# 11 结论

本文将 Paulo & Belrose (2025) 观察到的 SAE 字典种子敏感性现象解释为两层结构约束的必然显现，并给出形式化论证：

1. 在 L1 或 TopK 稀疏先验下，SAE 任务落入 Locatello 不可识别性区间；
2. 在 L-NL 架构与高容量设置下，三条已发表的局部约束联合给出可推导的误差下界，进而决定重合率的方向性塌缩；
3. 跨过 Locatello 门槛的已知途径是辅助变量，SAE 训练范式不天然提供，但可被改造提供。

本文不主张 SAE 解释性研究因此应被放弃，而是建议将其重新定位为对非唯一性分布的研究：SAE 字典作为一族解的代表元，其稳定成分（跨种子重合的 30%）与不稳定成分（漂移的 70%）各自反映模型表征结构的不同侧面，后者并非纯粹噪声，而是过完备表征容量在零空间中的具体实现。

本文最重要的诚实承认：所有不可识别性结论都建立在”无辅助变量可用”的假设上。该假设可被未来工作主动破坏 (§ 5.6 与 § 9.B.3)。本文的负面结论同时定义了正面研究的入口。



## A 引理 27 的完整证明

本附录补全引理 27 的证明，之前在正文中仅给出要点。

引理 27 完整证明. 设 SAE 学到的字典为  $\mathbf{W}_d \in \mathbb{R}^{M \times L}$ ，列归一化。我们要下界总误差  $\mathcal{E} = \epsilon_c + \lambda \epsilon_m$ 。

**步骤 1: 容量赤字下的不可恢复码集。**由引理 25，恢复  $\mathbb{R}^N$  中  $k$  稀疏向量的最少测量数为  $\Theta(k \log(N/k))$ 。设  $C_0 = \max(0, 1 - M/(k \log(N/k)))$ 。则  $\mathbb{R}^L$  中存在比例至少  $C_0$  的  $k$  稀疏码  $\mathbf{z}^*$ ，使任何线性编码器  $\mathbf{W}_e$  满足  $\Pr_{\mathbf{x}}[f_{\theta}(\mathbf{x}) = \mathbf{z}^*] = 0$ 。记该集合为  $\mathcal{F}_0$ ， $|\mathcal{F}_0|/|\mathcal{F}| \geq C_0$  ( $\mathcal{F}$  为全部  $k$  稀疏码)。

**步骤 2:  $\mathcal{F}_0$  上的重建误差下界。**对  $\mathbf{z}^* \in \mathcal{F}_0$ ，由定理 22 (Cui 等的干涉主导下界)，

$$\mathbb{E}_{\mathbf{z}^* \in \mathcal{F}_0} \|\mathbf{x} - \mathbf{W}_d \hat{\mathbf{z}}\|^2 \geq c_1 \cdot \|\mathcal{I}\|_2 \cdot \mathbb{E}_{\mathbf{z}^* \in \mathcal{F}_0} \|\mathbf{z}^*\|^2.$$

将  $\mathbb{E}_{\mathcal{F}_0}$  与  $\mathbb{E}_{\mathcal{F}}$  关联:  $\mathbb{E}_{\mathcal{F}_0}[\cdot] \geq C_0 \cdot \mathbb{E}_{\mathcal{F}}[\cdot]$  (在  $\mathcal{F}_0$  占比  $\geq C_0$  时)。故

$$\epsilon_c \geq C_0 \cdot c_1 \cdot \|\mathcal{I}\|_2 \cdot \mathbb{E} \|\mathbf{z}^*\|^2.$$

**步骤 3: 单义性误差的不相干性破缺下界。**由定理 23 (Bhalla 等的  $\mu$  阈值) 与定义 24，当  $L$  超出 Welch-Bhalla 阈值时，字典必须满足  $\mu \geq \mu_{\min} = \sqrt{(L-M)/(M(L-1))} > 1/(2k-1)$ 。违反的代数后果是字典基向量被迫承载多个真实因子的纠缠投影，即单义性误差与破缺成正比：

$$\epsilon_m \geq c_2 \cdot \Delta\mu,$$

其中  $c_2 > 0$  为依赖  $k$  与字典维度的常数。在  $\mathcal{F}_0$  上，这一项独立于  $\|\mathcal{I}\|_2$  的贡献存在： $\mathcal{F}$  在投影到不同字典原子时的混叠由  $\mu$  决定，而  $\mu$  由几何强制，与编码器的覆盖能力  $\|\mathcal{I}\|_2$  是不同的失败模式。

**步骤 4: 合并。**

$$\mathcal{E} = \epsilon_c + \lambda \epsilon_m \geq C_0 \cdot c_1 \|\mathcal{I}\|_2 \mathbb{E} \|\mathbf{z}^*\|^2 + \lambda C_0 c_2 \Delta\mu$$

(在步骤 3 中我们隐式使用  $\mathcal{F}_0$  是误差饱和的子集，故  $\epsilon_m$  的下界也乘以  $C_0$  作为”误差激活的相对体积”修正)。取  $C_1 := c_1 \mathbb{E} \|\mathbf{z}^*\|^2$ ， $C_2 := \lambda c_2$ ，即得

$$\mathcal{E}_{\min} \geq C_0 \cdot (C_1 \|\mathcal{I}\|_2 + C_2 \Delta\mu). \quad \square$$

**评述 36.** 本证明的”软”步骤是步骤 3 中将 Bhalla 不等式从精确恢复阈值转化为单义性误差的具体下界  $c_2 \Delta\mu$ 。该转化的精确常数依赖 Bhalla 原证明中对  $\mu > 1/(2k-1)$  区间的退化分析，本附录未对其做独立追踪。

## B 工作样本：线性 SAE 的精确计算

为提供下界的可验证锚点，本附录在线性 SAE 这一可解情形下显式计算所有量。

### B.1 设置

设  $\sigma$  为恒等映射 (即 SAE 退化为 PCA-like 线性自编码器)， $\mathbf{W}_e = \mathbf{W}_d^\top$  (绑权重 tied weights)，列归一化。此时  $f_{\theta}(\mathbf{x}) = \mathbf{W}_d^\top \mathbf{x}$ ， $\hat{\mathbf{x}} = \mathbf{W}_d \mathbf{W}_d^\top \mathbf{x}$ 。

## B.2 $\mathcal{I}$ 的精确刻画

$\mathcal{I} = \mathbf{W}_d^\top \mathbf{W}_d - I_L$ 。  $\mathbf{W}_d^\top \mathbf{W}_d \in \mathbb{R}^{L \times L}$  的秩  $\leq M$ 。当  $L > M$  时,  $\mathcal{I}$  有至少  $L - M$  个特征值为  $-1$  (对应  $\mathbf{W}_d^\top \mathbf{W}_d$  的零空间), 故

$$\|\mathcal{I}\|_2 \geq 1.$$

等号在  $\mathbf{W}_d$  列两两正交 (仅在  $L \leq M$  时可能) 时成立。

## B.3 $\Delta\mu$ 的精确刻画

由 Welch 界 [15], 对  $L > M$ ,

$$\mu \geq \mu_W := \sqrt{\frac{L - M}{M(L - 1)}}.$$

当  $L = M$  时  $\mu_W = 0$  (字典可正交); 当  $L = 2M$  时  $\mu_W = \sqrt{1/(2M - 1)} \approx 1/\sqrt{2M}$ ; 当  $L \rightarrow \infty$  时  $\mu_W \rightarrow 1/\sqrt{M}$ 。

代入定义 24:

$$\Delta\mu = \max(0, \mu_W - 1/(2k - 1)).$$

对  $M = 64, k = 4$ ,  $1/(2k - 1) = 1/7 \approx 0.143$ , 当  $L \geq 8M = 512$  时  $\mu_W \approx \sqrt{1/64} = 0.125 < 0.143$ ,  $\Delta\mu = 0$ 。故对此参数组合, 不相干性破缺项尚未激活, 主导项来自  $\|\mathcal{I}\|_2$ 。

## B.4 $C_0$ 的精确刻画

对  $N = 1024, M = 64, k = 4$ :  $k \log(N/k) = 4 \log(256) \approx 4 \cdot 8 = 32$  (自然对数下约 22)。  
 $C_0 = \max(0, 1 - 64/32) = 0$ 。故对此设置  $M$  充分大, 容量赤字不激活。

## B.5 结论

线性 SAE 在  $M$  充分大、 $k$  充分小、 $L$  不过分大时, 本文下界主导项仅有  $\|\mathcal{I}\|_2 \geq 1$  的常数贡献, 表现为对总误差的常数下界, 不导致重合率塌缩。重合率塌缩需要进入大  $L$ 、大  $k$ 、小  $M$  的”难”参数区。这一计算说明本文标度律预言 31–33 在对应参数极限下的方向是自洽的。

## 参考文献

- [1] Paulo, G., & Belrose, N. (2025). *Sparse Autoencoders Trained on the Same Data Learn Different Features*. arXiv preprint arXiv:2501.16615.
- [2] Elhage, N., et al. (2022). *Toy Models of Superposition*. Transformer Circuits Thread.
- [3] Locatello, F., Bauer, S., Lucic, M., Rätsch, G., Gelly, S., Schölkopf, B., & Bachem, O. (2019). *Challenging Common Assumptions in the Unsupervised Learning of Disentangled Representations*. ICML.
- [4] Hyvärinen, A., & Pajunen, P. (1999). *Nonlinear independent component analysis: Existence and uniqueness results*. Neural Networks, 12(3), 429–439.

- [5] O’Neill, C., Gumran, A., & Klindt, D. (2024). *Compute Optimal Inference and Provable Amortisation Gap in Sparse Autoencoders*. arXiv preprint arXiv:2411.13117.
- [6] Cui, J., Zhang, Q., Wang, Y., & Wang, Y. (2026). *On the Limits of Sparse Autoencoders: A Theoretical Framework and Reweighted Remedy*. ICLR.
- [7] Bhalla, U., et al. (2026). *Do Sparse Autoencoders Capture Concept Manifolds?* arXiv preprint arXiv:2604.28119.
- [8] Zheng, Y., Li, Z., Fan, S., Wilson, A. G., & Zhang, K. (2026). *Diverse Dictionary Learning*. arXiv preprint arXiv:2604.17568.
- [9] Khemakhem, I., Kingma, D. P., Monti, R. P., & Hyvärinen, A. (2020). *Variational Autoencoders and Nonlinear ICA: A Unifying Framework*. AISTATS.
- [10] Hyvärinen, A., Sasaki, H., & Turner, R. E. (2019). *Nonlinear ICA Using Auxiliary Variables and Generalized Contrastive Learning*. AISTATS.
- [11] Candès, E. J., Romberg, J., & Tao, T. (2006). *Robust uncertainty principles: Exact signal reconstruction from highly incomplete frequency information*. IEEE Transactions on Information Theory, 52(2), 489–509.
- [12] Candès, E. J. (2008). *The restricted isometry property and its implications for compressed sensing*. Comptes Rendus Mathématique, 346(9-10), 589–592.
- [13] Donoho, D. L., & Elad, M. (2003). *Optimally sparse representation in general (nonorthogonal) dictionaries via  $\ell^1$  minimization*. PNAS, 100(5), 2197–2202.
- [14] Tropp, J. A. (2004). *Greed is good: Algorithmic results for sparse approximation*. IEEE Transactions on Information Theory, 50(10), 2231–2242.
- [15] Welch, L. R. (1974). *Lower bounds on the maximum cross correlation of signals*. IEEE Transactions on Information Theory, 20(3), 397–399.
- [16] Johnson, W. B., & Lindenstrauss, J. (1984). *Extensions of Lipschitz mappings into a Hilbert space*. Contemporary Mathematics, 26, 189–206.
- [17] Bricken, T., et al. (2023). *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning*. Transformer Circuits Thread.
- [18] Templeton, A., et al. (2024). *Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet*. Transformer Circuits Thread.